

Bevezető óra

Haladó adatelemzési módszerek laboratórium, 2025. február 24.

Előzetes ütemterv

1. Felvezetés, választható feladatok ismertetése, feladatkiadás (online)
2. online konzultációs lehetőség órarendi időben (ma)
3. M1: Projektterv bemutatás, Adatelőkészítés terv (jelenléti)
4. online konzultációs lehetőség órarendi időben
5. M2: Adatelőkészítés bemutatás, Adatvizualizáció terv (jelenléti)
6. Március 24. kedd: Simonyi konferencia (Dékáni szünet), online konzultációs lehetőség nem órarendi időben
7. M3: Adatvizualizáció bemutatás, feature engineering és adatrűsítés?, GT modellek terv (jelenléti)
8. Húsvéti szünet
9. online konzultációs lehetőség órarendi időben
10. M4: GT modellek bemutatás, GT értékelés terv (jelenléti)
11. online konzultációs lehetőség órarendi időben
12. M5: GT értékelés bemutatás, Alkalmazás terv (jelenléti)
13. online konzultációs lehetőség órarendi időben
14. M6: Alkalmazás bemutatás (jelenléti)
15. Pótlási lehetőség

Előkészületek

Javasolt eszközök:

- Visual Studio Code
- ML/DL környezet: miniconda docker image (python, jupyter, pandas, matplotlib, scikit-learn)
- érdemes mindezt docker környezetben megtenni (pl. Docker Desktop, continuumio/miniconda3)

Az adathalmaz

- Adatforrás: <https://shorturl.at/ti9ev>
- A tárhelyen gzip-pel tömörített formában találjuk
- A kibontott fájlok listája:
 - SCLDDoS2024_SetA_components.csv
 - SCLDDoS2024_SetA_events.csv
 - SCLDDoS2024_SetB_components.csv
 - SCLDDoS2024_SetB_events.csv
 - SCLDDoS2024_SetC_components.csv
 - SCLDDoS2024_SetC_events.csv
 - SCLDDoS2024_SetD_components.csv
 - SCLDDoS2024_SetD_events.csv

Az adathalmaz

- Betanításhoz:

SCLDDoS2024_SetA_components.csv

SCLDDoS2024_SetA_events.csv

SCLDDoS2024_SetB_components.csv

SCLDDoS2024_SetB_events.csv

- Teszteléshez:

SCLDDoS2024_SetC_components.csv

SCLDDoS2024_SetC_events.csv

- Generikusság ellenőrzéséhez:

SCLDDoS2024_SetD_components.csv

SCLDDoS2024_SetD_events.csv

Az adathalmaz

Az események (events) halmaz szerkezete:

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	AttackID	Card	Victim IP	Port number	Attack code	Detect count	Significant flag	Packet speed	Data speed	Avg packet len	Avg source IP count	Start time	End time	Whitelist flag	Type
2	1	sga10gq0	IP_0001	4500	High volume traffic	1	0	55600	73	1383	6	2022-08-08T18:09:36	2022-08-08T18:09:37	0	Normal traffic

- Attack ID: egyedi esemény azonosító
- Card: hálózati kártya azonosító
- Victim IP: anonimizált cél IP (a teljes adathalmazon egyedi)
- Port number: cél port száma
- Attack code: a legfontosabb összetevő jellege
- Detect count: az esemény összetevőinek száma
- Significant flag: a DDoS detektor belső használatú flagje (számunkra irreleváns)
- Packet speed: csomagrátá (pps)
- Data speed: adatrátá (bps)
- Avg packet len: átlagos csomaghossz (byte)
- Avg source IP count: a komponensekben érintett IP-k átlagos száma
- Start time: az esemény kezdetének ideje (dátummal)
- End time: az esemény végének ideje (dátummal)
- Whitelist flag: a DDoS detektor belső használatú flagje (számunkra irreleváns)
- **Type: az esemény kategóriája (aminként a DDoS detektor felcímkézte)**

Az adathalmaz


Az összetevők (components) halmaz szerkezete:

	A	B	C	D	E	F	G	H	I	J	K	L
1	Attack ID	Detect count	Card	Victim IP	Port number	Attack code	Significant flag	Packet speed	Data speed	Avg packet len	Source IP count	Time
2	1	1	sga10gq0	IP_0001	4500	High volume traffic	0	55600	73	1383	6	2022-08-08T18:09:36

- Attack ID: egyedi esemény azonosító
- Detect count: az összetevő azonosító száma (az eseményen belül)
- Card: hálózati kártya azonosító
- Victim IP: anonimizált cél IP
- Port number: cél port száma
- Attack code: az összetevő jellege
- Significant flag: a DDoS detektor belső használatú flagje (számunkra irreleváns)
- Packet speed: csomagrata (pps)
- Data speed: adatrata (bps)
- Avg packet len: átlagos csomaghossz (byte)
- Source IP count: forrás IP-k száma
- Time: az esemény összetevőjének kezdő ideje (dátummal)


Adatvizualizáció

Eseménytípusok eloszlása SetA events-ben:



Adatvizualizáció

Az esemény kategóriák időbeni megoszlása:



Hasznos linkek

1. Visualizing Network Data Using Python: Part 1, 2,
<https://www.automox.com/blog/visualizing-network-data-using-python-part-1>
<https://www.automox.com/blog/visualizing-network-data-using-python-part-2>

Hasznos linkek kezdő szinthez

1. Wine quality DL ANN tutorial:
<https://www.datacamp.com/tutorial/deep-learning-python>
2. Jupyter: <https://docs.jupyter.org/>
3. Pandas: <https://pandas.pydata.org/docs/>
4. Plotly Express: <https://plotly.com/python/plotly-express/>
5. Scikit-Learn
<https://scikit-learn.org/stable/api/index.html>
6. Random Forest tutorial:
<https://www.datacamp.com/tutorial/random-forests-classifier-python>
7. CatBoost tutorial: <https://www.datacamp.com/tutorial/catboost>

Személyes konzultáció

A személyes konzultációs alkalom helyszíne: I.B21 1